

Reporte Técnico: Sistema End-to-End de Visión de Computador para Alarma Inteligente Basado en YOLOv11 y Gradio

Maria Isabel Posada Niasa, Lina Robsana Jamioy
Universidad Nacional de Colombia

Resumen

Este documento técnico describe el diseño, optimización y despliegue en producción de un sistema de visión artificial adaptativo orientado a la seguridad del hogar. El núcleo del sistema utiliza una arquitectura de red neuronal convolucional basada en YOLOv11m, la cual fue modificada y rebalanceada desde un dataset original de 20 clases hacia una taxonomía reducida de 8 macro-clases funcionales para mitigar el sesgo estadístico. El modelo final fue optimizado mediante cuantización en formato TorchScript y desplegado de extremo a extremo (End-to-End) en la nube a través de la infraestructura de Hugging Face Spaces empleando una interfaz gráfica interactiva desarrollada en Gradio. Los resultados experimentales confirman una alta tolerancia al sobreajuste y una convergencia asintótica de las funciones de pérdida distribuidas.

Index Terms

YOLOv11, Visión por Computador, Despliegue de Modelos, Hugging Face, Gradio, Redes Neuronales Convolucionales, Seguridad Residencial.

I. INTRODUCCIÓN

Los sistemas tradicionales de alarma residencial basados en sensores infrarrojos pasivos (PIR) presentan limitaciones críticas asociadas a altas tasas de falsos positivos provocados por dinámicas domésticas comunes. El Procesamiento Digital de Imágenes (PDI) y el aprendizaje profundo ofrecen un paradigma robusto para la clasificación e identificación contextual de amenazas.

Este proyecto implementa una solución de software e ingeniería de IA capaz de discriminar entre objetos de la vida cotidiana y vectores de riesgo potenciales. A lo largo del informe se detalla el pipeline completo, abarcando el preprocesamiento taxonómico, el entrenamiento gobernado por pérdidas multiescala, la auditoría metrológica de la red y el empaquetado del artefacto para entornos productivos en la nube.

II. INGENIERÍA DE DATOS Y BALANCEO TAXONÓMICO

El conjunto de datos original sufría de una fragmentación taxonómica severa y un desbalance crítico de clases, separando elementos geoméricamente similares (como tazas, platos y cucharas). Esta granularidad excesiva en escenarios residenciales con oclusiones e iluminación variable degrada la capacidad de generalización del gradiente.

Como estrategia de mitigación, se diseñó un mapeo de ingeniería para colapsar las 20 categorías originales en 8 macro-clases estratégicas alineadas con la lógica de negocio de la alarma:

- **dishes_utensils:** Unificación de tazas, platos y utensilios de cocina. Utilizado operativamente como el token visual de desactivación segura del sistema.
- **electronics:** Dispositivos de comunicación como teléfonos y laptops.
- **appliances:** Grandes y pequeños electrodomésticos (microondas, refrigeradores).

- **security_access:** Patrones definidos de llaves y tarjetas de acceso.
- **sharp_objects:** Vectores de riesgo explícitos como cuchillos y herramientas cortantes.

Esta reestructuración incrementó significativamente la densidad de muestras por categoría, estabilizando la varianza del modelo durante la etapa de optimización.

III. ARQUITECTURA DEL MODELO Y FUNCIONES DE PÉRDIDA

Se seleccionó el detector de objetos de última generación **YOLOv11**, optimizando sus hiperparámetros para la arquitectura de tamaño mediano (YOLOv11m). Durante el proceso de retropropagación, la red minimiza una función objetivo compuesta, diseñada para resolver tres tareas ortogonales en paralelo:

$$Loss_{total} = \lambda_{box} Loss_{box} + \lambda_{cls} Loss_{cls} + \lambda_{dfl} Loss_{dfl} \quad (1)$$

Donde los coeficientes λ regulan el impacto relativo de cada pérdida.

III-A. Pérdida de Localización (Box Loss)

La componente $Loss_{box}$ evalúa la discrepancia geométrica entre las *Bounding Boxes* predichas y las etiquetas reales. Utiliza la métrica de Intersección sobre Unión Completa (CIoU), minimizando los errores de centrado espacial (x, y) y la consistencia de aspecto en las dimensiones de escala (ancho w , alto h).

III-B. Pérdida de Clasificación (Classification Loss)

Basada en Entropía Cruzada Binaria (BCE), la $Loss_{cls}$ penaliza los errores de asignación de categorías para cada anclaje de la red. En esta fase, la pérdida fuerza a la red a converger hacia las 8 macro-clases funcionales previamente balanceadas.

III-C. Distribution Focal Loss (DFL)

Para refinar el aprendizaje en condiciones ocluidas o bordes difusos (comunes en espacios internos con iluminación deficiente), se emplea la Distribution Focal Loss. En lugar de predecir coordenadas como valores discretos rígidos, la DFL modela los límites de las cajas como distribuciones de probabilidad continuas, mejorando la detección de objetos de escala pequeña.

IV. EVALUACIÓN EXPERIMENTAL Y VALIDACIÓN METROLÓGICA

El análisis analítico de convergencia extraído de los históricos de entrenamiento (`results.png`) reveló que tanto las pérdidas de entrenamiento como las de validación disminuyeron continuamente de forma asintótica. Esto constituye una evidencia matemática directa de que la red neuronal no experimentó sobreajuste (*Overfitting*).

El rendimiento óptimo se evaluó mediante la curva F1-Confidence, determinando que el modelo alcanza su punto de equilibrio armónico global con un **F1-Score** de 0.68 a un umbral de confianza de 0.375** para todas las clases combinadas. Las categorías altamente estructuradas como `security_access` exhibieron puntuaciones máximas cercanas a 0.89, validando el impacto positivo del balanceo taxonómico inicial.

V. ARQUITECTURA DE DESPLIEGUE EN LA NUBE (PRODUCCIÓN)

Para la transición desde la fase de experimentación científica (Google Colab) hacia un entorno operativo real, se construyó un pipeline de despliegue automatizado basado en microservicios encapsulados.

V-A. *Compilación y Control de Dependencias*

Se estructuró el archivo de configuración en frío `requirements.txt`, aislando las versiones de las librerías del núcleo de inferencia para prevenir colisiones en tiempo de ejecución:

- `ultralitics==8.3.0` (o la versión correspondiente utilizada)
- `gradio>=4.0.0`
- `torch` y `torchvision`

V-B. *Interfaz Interactiva y Lógica de Servidor*

A través de un script centralizador (`app.py`), se levantó un servidor web en la infraestructura cloud de **Hugging Face Spaces**. La lógica de ejecución del software se divide en las siguientes etapas consecutivas:

1. **Inicialización:** El contenedor Docker levanta la instancia y carga en memoria estática los pesos optimizados del archivo de entrenamiento binario `best.pt`.
2. **Ingreso de Flujo Multimedia:** La interfaz de Gradio expone canales para la captura de flujos desde la cámara web en vivo del usuario o mediante la carga directa de archivos locales (e.g., `prueba_taza.jpeg`).
3. **Inferencia Funcional:** La imagen capturada es transformada matricialmente e inyectada al método predictor de la red neuronal.
4. **Desencadenamiento de Alarma:** El backend ejecuta la lógica de negocio; si la macroclase `dishes_utensils` se detecta con una confianza superior al umbral operativo ($\tau = 0,375$), el script conmuta automáticamente el estado del sistema a `DESACTIVADO`, de lo contrario, se activa el protocolo de alerta residencial.

VI. CONCLUSIONES

Se ha completado con éxito el ciclo completo de desarrollo de una solución basada en Inteligencia Artificial. El balanceo de datos estratégico demostró ser la variable más influyente para mitigar el sesgo estadístico en entornos complejos de visión artificial. Asimismo, el despliegue funcional en Hugging Face demuestra que los modelos matemáticos abstractos pueden transformarse en herramientas operativas interactivas, seguras y de alta disponibilidad para el usuario final.